

BEHAVIOR-1K 기반 양팔 로봇 정책 학습


지도 교수님: 하종은 교수님

연구 목적


- BEHAVIOR-1K 환경에서 Vision-Language-Action 기반 양팔 로봇 조작 정책을 구현하고 평가
- Pi0.5 기반 모델을 활용하여 장기 시퀀스 작업 수행 성능을 분석하고, Flow Matching 기반 정책 학습 구조를 적용
- OmniGibson 환경에서 다양한 작업 수행 결과를 통해 모델의 실효성 검증

BEHAVIOR-1K

OmniGibson 기반 가정환경 시뮬레이션 벤치마크로, 로봇의 장기 작업 수행.이동.양팔 조작.물체 상호작용 능력을 평가하는 데이터셋 및 환경



모델 구조



Model Architecture

Backbone: OpenPI의 Pi0.5 기반 구조
(SigLIP + PaliGemma + Flow Matching Action Expert)

System 2 Stage Tracking : 현재 작업 진행 단계 예측 및 추적


Task Embedding : 작업 종류를 벡터로 표현하는 조건 정보

FAST Auxiliary : 행동 시퀀스를 토큰화해 보조 학습

Correlated Noise : 행동 간 시간적·공간적 상관관계를 반영한 노이즈

KV Transform : VLM의 Key/Value 정보를 조합해 attention 활용 개선

Custom Attention Masks : token 간 정보 흐름을 제한해 학습 안정성 향상



실험 환경

1. Hardware Environment

A100 80GB GPU Server, RTX 5070 PC, Ubuntu + JAX/Flax

2. 실험 및 모델 경량화

	1st	경량화 모델
GPU	H200 x 8 RTX 4090 x 20	A100 x 1 RTX 5070 x 2
Task	50	12
Batch size	2048	16
Step	200,000	70,000
Flow sample	15	1
evaluation	50 task x 10 instance	12 task x 1 instance

3. Selected 12 Tasks

Turning on radio, Picking up trash, Setting mousetraps, Putting dishes away, Preparing lunch box, Outfit a basic toolbox, Putting shoes on rack, Clean boxing gloves, Spraying fruit trees, Make microwave popcorn, Cook hot dogs, Cook bacon

참고 문헌

- Ilia Larchenko, Gleb Zarin, Akash Karnatak, "Task Adaptation of Vision-Language-Action Model: 1st Place Solution for the 2025 BEHAVIOR Challenge", 2025, arXiv:2512.06951.
- Marcel Torne et al., "MEM: Multi-Scale Embodied Memory for Vision Language Action Models", 2026, arXiv:2603.03596.
- Yalcin Tur et al., "Recurrent-Depth VLA: Implicit Test-Time Compute Scaling of Vision-Language-Action Models via Latent Iterative Reasoning", 2026, arXiv:2602.07845.
- Ali Amin et al., "π*0.6: A VLA That Learns From Experience", 2025, arXiv:2511.14759.

조원: 강지호, 문병선

주차별 진행 상황 및 역할 분담


- 1주차: 프로젝트 주제 선정 및 개발 환경 조사
- 2주차: OpenPI-Pi0.5 기반 코드 구조 분석 및 학습 파이프라인 구축
- 3주차: 모델 구조 설계 및 실험 환경 구성
- 4주차: OmniGibson 평가 환경 구축
- 5주차: 실데이터 학습 파이프라인 구현

- 6주차: 메모리 최적화 및 학습 성능 분석
- 7주차: 학습 및 W&B 로깅 시스템 구축
- 8주차: 경량화 모델 학습
- 9주차: 경량화 모델 학습
- 10주차: 경량화 모델 학습
- 11주차: rollout 안정화 및 평가 개선
- 12주차: 최종 실험 결과 정리

강지호: VLA 모델 구현·학습 및 핵심 알고리즘 실험 진행


문병선: OmniGibson 평가 환경 구축·영상 생성 및 결과 정리

결과



System2 stage/subtask prediction의 정확도

$$Accuracy = \frac{\text{Number of Correct Prediction}}{\text{Total Prediction}}$$



모델의 전체 학습 손실(total loss)

$$L_{total} = L_{action} + \lambda_s L_{stage} + \lambda_f L_{FAST}$$

결과 분석

1. 학습 및 파이프라인 검증

Total loss 감소 및 stage accuracy 향상

W&B logging / checkpoint 저장 검증

A100-RTX5070 기반 rollout pipeline 구축

2. 결과 비교

평가지표	task_00 turning_on_radio inst 295	task_01 picking_up_trash inst 67	task_05 setting_mousetraps inst 296	task_11 putting_dishes_away_after_dinner inst 173	task_12 preparing_lunch_box inst 214	task_19 outfit_a_basic_toolbox inst 43	task_22 putting_shoes_on_rack inst 282	task_31 clean_boxing_gloves inst 265	task_39 spraying_fruit_trees inst 160	task_40 make_microwave_popcorn inst 222	task_45 cook_hot_dogs inst 158	task_46 cook_bacon inst 210	평균
1st Team Q-score	0.000	0.000	0.333	0.000	0.000	0.000	0.100	0.000	0.000	1.000	0.000	0.000	0.119
1st Team Accuracy	0	0	0	0	0	0	0	0	0	1	0	0	0.083
경량화 모델 Q-score	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000
경량화 모델 Accuracy	0	0	0	0	0	0	0	0	0	0	0	0	0.000

3. Rollout 성능 한계

OOD 상태에서 freeze·반복 행동 발생

Normalization 및 action scale 차이로 base 불안정

Stage tracking 및 정밀 조작 성능 한계 확인

향후 계획

1. 학습 관련

학습 step 증가를 통한 장기 수렴 성능 분석

다양한 seed 활용 및 task 수 확장 통한 일반화 성능 향상

2. 추가 VLA 기술

MeM (Multi-Scale Embodied Memory): short-term / long-term memory 기반 long-horizon task 안정성 향상

RD-VLA (Recurrent-Depth VLA): 잠재 행동 계획을 반복적으로 정교화하여 장기 작업에서 더 정밀한 행동 궤적 생성

π*0.6-lite Recovery Learning: 실패 rollout과 stage/value 정보를 활용하여 OOD 상태에서 복구 행동 및 rollout 안정성 향상